A decorative graphic on the left side of the slide consists of a grid of colored squares. The grid is 4 rows high and 4 columns wide. The colors of the squares are: Row 1: Teal, Orange, Brown, Teal; Row 2: Orange, Brown, Teal, Brown; Row 3: Orange, Teal, Brown, Brown; Row 4: Brown, Orange, Orange, Brown. The text is positioned to the right of this grid.

# Линейная классификация и метрики качества классификации

**Повторение**

# Среднеквадратичная ошибка

- MSE для линейной регрессии:

$$\frac{1}{l} \|Xw - y\|^2 \rightarrow \min_w$$

$$Q(w_1, \dots, w_d) = \frac{1}{l} \sum_{i=1}^l (w_1 x_{1i} + \dots + w_d x_{di} - y_i)^2$$

Можно посчитать градиент MSE:

- $\nabla \frac{1}{l} \|Xw - y\|^2 = \frac{2}{l} X^T (Xw - y)$

Приравниваем нулю и решаем систему линейных уравнений:

- $w = (X^T X)^{-1} X^T y$

# Аналитическое решение


$$w = (X^T X)^{-1} X^T y$$

- Если матрица  $(X^T X)$  вырожденная, то будут проблемы
- Даже если она почти вырожденная, все равно будут проблемы
- Если признаков много, то придется долго ждать
- Обращение матрицы – сложная операция ( $O(N^3)$  от числа признаков
- Если заменить среднеквадратичный функционал на другой, то скорее всего не найдем аналитическое решение

# Метод градиентного спуска


- Наша задача при обучении модели – найти такие веса  $w$ , на которых достигается минимум функции ошибки.
- Грубо говоря, график MSE – парабола
- Идея метода градиентного спуска.
- На каждом шаге движемся в сторону антиградиента функции потерь!
- Вектор градиента функции потерь обозначают  $grad\ Q$  или  $\nabla Q$

# Метод градиентного спуска



# Производная

$$\lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0} = f'(x_0)$$




# Градиент

- Градиент – вектор частных производных

$$\nabla f(x) = \left( \frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_d} \right)$$

- У градиента есть важное свойство!
- Зафиксируем точку  $x_0$
- В какую сторону функция быстрее всего растёт?





# Градиентный спуск

Повторять до сходимости:

$$w^t = w^{t-1} - \eta \nabla Q(w^{t-1})$$

Новая точка

Длина шага

Градиент в предыдущей точке

The diagram illustrates the components of the gradient descent update formula. Three light blue arrows originate from the text labels below and point to specific parts of the equation  $w^t = w^{t-1} - \eta \nabla Q(w^{t-1})$ . The first arrow, labeled 'Новая точка' (New point), points to  $w^t$ . The second arrow, labeled 'Длина шага' (Step size), points to the learning rate  $\eta$ . The third arrow, labeled 'Градиент в предыдущей точке' (Gradient at the previous point), points to the gradient term  $\nabla Q(w^{t-1})$ .

# Метод градиентного спуска

На каждом шаге ( на каждой итерации метода) движемся в сторону антиградиента Функции потерь!

- Инициализируем веса  $w_0^{(0)}, w_1^{(1)}, w_2^{(0)}, \dots, w_n^{(0)}$
- На каждом следующем шаге обновляем веса, сдвигаясь в направлении антиградиента функции потерь  $Q$ :

$$w_0^{(k)} = w_0^{(k-1)} - \nabla Q(w_0^{(k-1)}),$$

$$w_1^{(k)} = w_1^{(k-1)} - \nabla Q(w_1^{(k-1)}),$$

...

$$w_n^{(k)} = w_n^{(k-1)} - \nabla Q(w_n^{(k-1)}),$$

# Градиентный спуск

Останавливаем процесс, если

$$\|w^t - w^{t-1}\| < \varepsilon$$

Другой вариант;

$$\|Q(w^t) - Q(w^{t-1})\| < \varepsilon$$

Другой вариант:

$$\|\nabla Q(w^t)\| < \varepsilon$$

# Переменная длина шага

$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1})$$

- Длину шага можно менять в зависимости от шага
- Например:  $\eta_t = \frac{1}{t}$
- Шаг наискорейшего спуска:  
 $\eta_t = \operatorname{argmin}_\eta Q(w^t) = \operatorname{argmin}_\eta Q(w^{t-1} - \eta \nabla Q(w^{t-1}))$

# Оценка градиента

$$Q(w) = \frac{1}{l} \sum_{i=1}^l L(y_i, a(x_i))$$

- Градиент:

$$\nabla Q(w) = \frac{1}{l} \sum_{i=1}^l \nabla L(y_i, a(x_i))$$

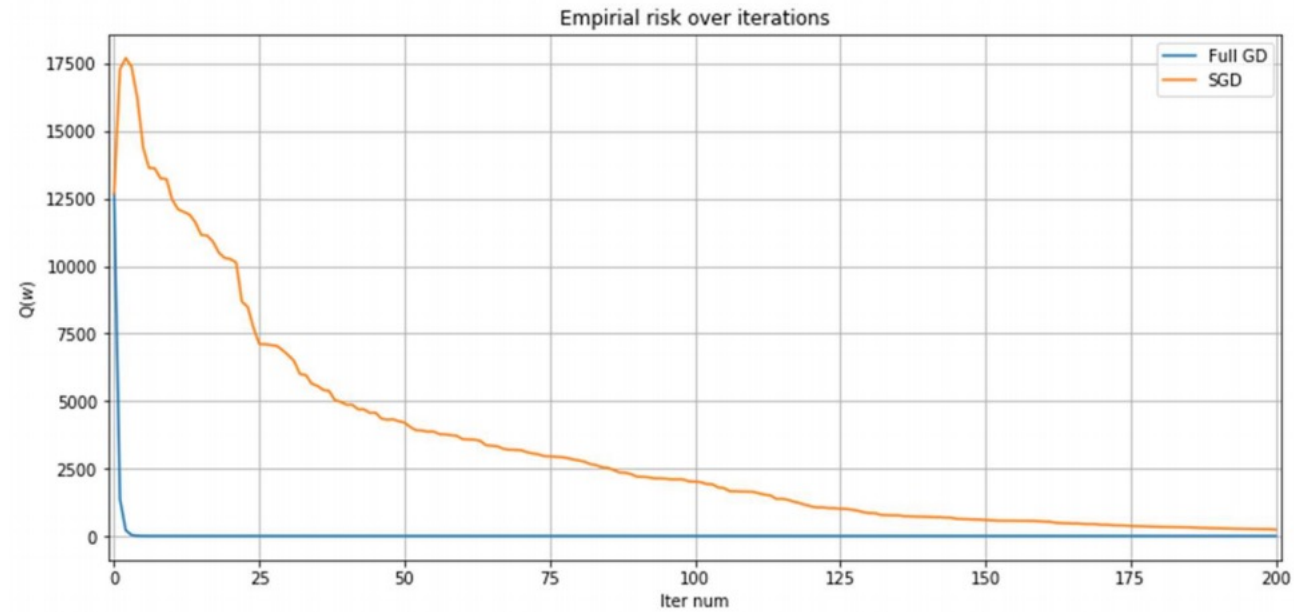
- Может, оценить градиент одним слагаемым?

$$\nabla Q(w) \approx \frac{1}{l} \sum_{i=1}^l \nabla L(y_i, a(x_i))$$

# Стохастический градиентный спуск

1. Начальное приближение:  $w^0$
2. Повторять, каждый раз выбирая случайный объект  $i_t$  :  $w^t = w^{t-1} - \eta_t \nabla L(y_{i_t}, a(x_{i_t}))$
3. Останавливаемся, если 
$$\|w^t - w^{t-1}\| < \varepsilon$$

# Стохастический градиентный спуск



# Стохастический градиентный спуск

1. Начальное приближение:  $w^0$
2. Повторять, каждый раз выбирая  $m$  случайный объект  $i_1, \dots, i_m$  :  
$$w^t = w^{t-1} - \eta_t \frac{1}{m} \sum_{j=1}^m \nabla L(y_{i_j}, a(x_{i_j}))$$
3. Останавливаемся, если  
$$\|w^t - w^{t-1}\| < \varepsilon$$



# **Модель линейной классификации**

# Классификация

- $Y = \{-1, +1\}$
- -1 – отрицательный класс
- +1 – положительный класс
- Алгоритм  $a(x)$  должен возвращать одно из двух чисел

# Линейная регрессия

$a(x) = w_0 + \sum_{j=1}^d w_j x_j$  - выдает вещественное число

# Линейный классификатор

$$a(x) = \text{sign}(w_0 + \sum_{j=1}^d w_j x_j) - \text{выдает знак вещественного числа}$$

Свободный  
коэффициент

веса

признаки


# Линейный классификатор

$a(x) = \text{sign}(\sum_{j=1}^d w_j x_j) = \text{sign} \langle w, x \rangle$  добавим единичный признак

# Геометрия

Скалярное произведение :


$$\langle a, b \rangle = |a||b|\cos(\theta)$$



# Геометрия


Уравнение гиперплоскости:

$$\langle w, x \rangle = 0$$



# Геометрия

- Линейный классификатор проводит гиперплоскость
- $\langle w, x \rangle < 0$  – объект слева от нее
- $\langle w, x \rangle > 0$  – объект справа от нее






# Геометрия

- Расстояние от точки до гиперплоскости  $\langle w, x \rangle = 0$  :

$$\frac{|\langle w, x \rangle|}{\|w\|} = \frac{|\langle w, x \rangle|}{\sqrt{\langle w, w \rangle}}$$


- Чем больше  $\langle w, x \rangle$  , тем дальше объект от разделяющей гиперплоскости

# Геометрия



# Отступ

- $M_i = y_i \langle w, x_i \rangle$
- $M_i > 0$  - классификатор дает верный ответ
- $M_i < 0$  - классификатор ошибается
- Чем дальше отступ от нуля, тем больше уверенности



# Порог

$$a(x) = \text{sign}(\langle w, x \rangle - t)$$

$t$  - порог классификатора

Можно подбирать для оптимизации функции потерь, отличной  
От использованной при обучении

# Линейный классификатор

- Линейный классификатор разделяет два класса гиперплоскостью
- Чем больше отступ по модулю, тем дальше объект от гиперплоскости
- Знак отступа говорит о корректности предсказания

# **Обучение линейных классификаторов**

# Функция потерь в классификации


- Частый выбор – бинарная функция потерь  
 $L(y, a) = [a \neq y]$
- Функционал ошибки – доля ошибок (error rate)  
 $Q(y, a) = \frac{1}{l} \sum_{i=1}^l [a(x_i) \neq y_i]$
- Нередко измеряют долю верных ответов (accuracy):  
 $Q(y, a) = \frac{1}{l} \sum_{i=1}^l [a(x_i) = y_i]$

# Доля ошибок для линейного классификатора

- Функционал ошибки:

$$Q(w, X) = \frac{1}{l} \sum_{i=1}^l [\text{sign}(\langle w, x_i \rangle) \neq y_i]$$

- Индикатор – недифференцируемая функция





# Отступы для линейного классификатора

- Функционал ошибки:

$$Q(w, X) = \frac{1}{l} \sum_{i=1}^l [\text{sign}(\langle w, x_i \rangle) \neq y_i]$$


- Альтернативная запись:

$$Q(w, X) = \frac{1}{l} \sum_{i=1}^l [y_i \langle w, x_i \rangle < 0]$$

$y_i \langle w, x_i \rangle = M_i$  - отступ

# Отступы (MARGIN)


Ранжирование объектов по возрастанию отступа:



# Верхняя оценка

$$L(M) = [M < 0] \leq L^{\sim}(M)$$

Оценим сверху дифференцируемой функцией



# Верхняя оценка


$$0 \leq \frac{1}{l} \sum_{i=1}^l [y_i < w, x_i > < 0] \leq \frac{1}{l} \sum_{i=1}^l L^{\sim}(y_i < w, x_i >) \rightarrow \min_w$$

Минимизируем верхнюю оценку

Надеемся, что она прижмет долю ошибок к нулю

# Примеры верхних оценок

- $L^{\sim}(M) = \log(1 + e^{-M})$  – логистическая
- $L^{\sim}(M) = \max(0, 1 - M)$  – кусочно – линейная
- $L^{\sim}(M) = e^{-M}$  – экспоненциальная
- $L^{\sim}(M) = \frac{2}{1+e^M}$  - сигмоидная



# Пример обучения

Выбираем логистическую функцию потерь:

$$Q^{\sim}(w, X) = \frac{1}{l} \sum_{i=1}^l \log(1 + \exp(-y_i \langle w, x_i \rangle)) \rightarrow \min_w$$

Вычисляем градиент:

$$\nabla_w Q^{\sim}(w, X) = -\frac{1}{l} \sum_{i=1}^l \frac{y_i x_i}{1 + \exp(y_i \langle w, x_i \rangle)}$$

# Пример обучения

Делаем градиентный спуск

$$w^{(t)} = w^{(t-1)} + \eta \frac{1}{l} \sum_{i=1}^l \frac{y_i x_i}{1 + \exp(y_i \langle w, x_i \rangle)}$$

# Пример регуляризации

$$\frac{1}{l} \sum_{i=1}^l \log(1 + \exp(-y_i \langle w, x_i \rangle)) + \lambda \|w\|^2 \rightarrow \min_w$$

Полностью аналогично линейной регрессии

Важно не накладывать регуляризацию на свободный коэффициент

<https://medium.com/@shrutijadon10104776/why-we-dont-use-bias-in-regularization-5a86905dfcd6>



# **Метрики качества классификации**

# Качество классификации

- Доля неправильных ответов:

$$\frac{1}{l} \sum_{i=1}^l [a(x_i) \neq y_i]$$

- Доля правильных ответов:

$$\frac{1}{l} \sum_{i=1}^l [a(x_i) = y_i]$$

# Несбалансированные выборки

- Несбалансированная выборка — объектов одного класса существенно больше
- Пример: предсказание кликов по рекламе
- Пример: медицинская диагностика
- Пример: предсказание оттока клиентов
- Пример: специализированный поиск

# Несбалансированные выборки

- Пример:
  - Класс -1 : 950 объектов
  - Класс +1 : 50 объектов
  - $a(x) = -1$
  - Доля правильных ответов : 0.95
  - Почему результат нас не устраивает?
  - Модель не несет экономической ценности
  - Цены ошибок неравнозначны

# Несбалансированные выборки

- $q_0$  - доля объектов самого крупного класса
- Для разных алгоритмов :  
 $accuracy \in [q_0, 1]$
- Если получили большой ассигасу — посмотрите на баланс классов

# Улучшение метрики

- Два алгоритма
- Доли правильных ответов :  $r_1$  и  $r_2$
- Абсолютное улучшение:  $r_2 - r_1$
- Относительное отношение:  $\frac{r_2 - r_1}{r_1}$

# Улучшение метрики

- $r_1 = 0.8$ ,
- $r_2 = 0.9$ ,
- $\frac{r_2 - r_1}{r_1} = 12.5\%$

- $r_1 = 0.5$ ,
- $r_2 = 0.75$ ,
- $\frac{r_2 - r_1}{r_1} = 50\%$

- $r_1 = 0.001$ ,
- $r_2 = 0.01$ ,
- $\frac{r_2 - r_1}{r_1} = 900\%$

# Цены ошибок

Пример: кредитный скоринг

- Что хуже?
  - Выдать кредит «плохому» клиенту
  - Не выдать кредит «хорошему» клиенту
- Доля верных ответов не учитывает цены ошибок



# Матрица ошибок

|             | $Y = 1$             | $Y = -1$            |
|-------------|---------------------|---------------------|
| $a(x) = 1$  | True Positive (TP)  | False Positive (FP) |
| $a(x) = -1$ | False Negative (FN) | True Negative (TN)  |

# Матрица ошибок

Модель  $a_1(x)$ :

|             | $Y = 1$ | $Y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 80      | 20       |
| $a(x) = -1$ | 20      | 80       |

Модель  $a_2(x)$ :

|             | $Y = 1$ | $Y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 48      | 2        |
| $a(x) = -1$ | 52      | 98       |

# Точность (precision)

Можно ли доверять классификатору при  $a(x) = 1$ ?

$$precision(a, X) = \frac{TP}{TP + FP}$$

# Точность (precision)

Модель  $a_1(x)$ :

|             | $Y = 1$ | $Y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 80      | 20       |
| $a(x) = -1$ | 20      | 80       |

$\text{Precision}(a_1, X) = 0.8$

Модель  $a_2(x)$ :

|             | $Y = 1$ | $Y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 48      | 2        |
| $a(x) = -1$ | 52      | 98       |

$\text{Precision}(a_2, X) = 0.96$

# Полнота (recall)

Как много положительных объектов находит классификатор?

$$recall(a, X) = \frac{TP}{TP + FN}$$

# Полнота (recall)

Модель  $a_1(x)$ :

|             | $Y = 1$ | $Y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 80      | 20       |
| $a(x) = -1$ | 20      | 80       |


$$\text{recall}(a_1, X) = 0.8$$

Модель  $a_2(x)$ :

|             | $Y = 1$ | $Y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 48      | 2        |
| $a(x) = -1$ | 52      | 98       |

$$\text{recall}(a_2, X) = 0.48$$

# Точность и полнота



How many selected items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

How many relevant items are selected?

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

# Регулируем точность и полнота

Пусть  $p(x)$  – уверенность классификатора в том, что объект  $x$  относится к классу  $+1$ ,  $p(x) \in [0; 1]$

Обычно если  $p(x) > 0.5$ , то мы относим объект к положительному классу, а иначе – к отрицательному.

Можно изменять этот порог, то есть вместо 0.5 брать другое число из отрезка  $[0; 1]$ .



# Регулируем точность и полнота

Пусть  $p(x)$  – уверенность классификатора в том, что объект  $x$  относится к классу  $+1$ ,  $p(x) \in [0; 1]$

Обычно если  $p(x) > 0.5$ , то мы относим объект к положительному классу, а иначе – к отрицательному.

Можно изменять этот порог, то есть вместо 0.5 брать другое число из отрезка  $[0; 1]$ .

**Путем изменения порога  $t$  можно регулировать точность и полноту:**

- Например, если  $t = 0$ , то мы все объекты относим к положительному классу, то есть полнота = 1, а точность м
- При увеличении  $t$  полнота уменьшается (могут появиться объекты положительного класса, которые мы не нашли), а точность возрастет (появляются объекты положительного класса).

# Антифрод

- Классификация транзакций на нормальные и мошеннические
- Высокая точность, низкая полнота:
  - Редко блокируем нормальные транзакции
  - Пропускаем много мошеннических
- Низкая точность, высокая полнота:
  - Часто блокируем нормальные транзакции
  - Редко пропускаем мошеннические

# Кредитный скоринг

- Неудачных кредитов должно быть не больше 5%
- Ограничение:  $\text{precision}(a, X) \geq 0.95$
- Максимизируем полноту

# Медицинская диагностика

- Надо найти не менее 80% больных
- Ограничение:  $\text{recall}(a, X) \geq 0.8$
- Максимизируем точность

# Несбалансированные выборки

- $recall(a, X) = 0.1$
- $precision(a, X) = 0.33$
- $accuracy(a, X) = 0.99$


# **Совмещение точности и полноты**

# Точность и полнота

- Точность — можно ли доверять классификатору при  $a(x) = 1$ ?
- Полнота — как много положительных объектов находит  $a(x)$ ?
- Оптимизировать две метрики одновременно очень неудобно
- Как объединить?

# Арифметическое среднее

$$A = \frac{1}{2}(\textit{precision} + \textit{recall})$$






# Арифметическое среднее

$$A = \frac{1}{2}(\textit{precision} + \textit{recall})$$


- $\textit{precision} = 0.1$
- $\textit{recall} = 1$
- $A = 0.55$
- Плохой алгоритм



# Арифметическое среднее


$$A = \frac{1}{2}(\textit{precision} + \textit{recall})$$

- $\textit{precision} = 0.55$
- $\textit{recall} = 0.55$
- $A = 0.55$
- Нормальный алгоритм
- Но качество такое же,  
как у плохого



# Минимум


$$M = \min(\text{precision} + \text{recall})$$



# Минимум

$$M = \min(\text{precision} + \text{recall})$$


- $\text{precision} = 0.05$
- $\text{recall} = 1$
- $A = 0.05$



# Минимум

$$M = \min(\text{precision} + \text{recall})$$

- $\text{precision} = 0.55$
- $\text{recall} = 0.55$
- $M = 0.55$




# Минимум

$$M = \min(precision + recall)$$


- $precision = 0.4, recall = 0.5$
- $M = 0.4$
- $precision = 0.4, recall = 0.9$
- $M = 0.4$

Но второй алгоритм лучше!



# F-мера

$$F = \frac{2 * precision * recall}{precision + recall}$$






# F-мера

$$F = \frac{2 * precision * recall}{precision + recall}$$

- $precision = 0.4, recall = 0.5$
- $F = 0.44$
- $precision = 0.4, recall = 0.9$
- $F = 0.55$

Работает!






# F-мера

$$F = (1 + \beta^2 \frac{*precision * recall}{\beta^2 * precision + recall})$$

$$\beta = 0.5$$

Важнее точность




# F-мера

$$F = (1 + \beta^2 \frac{*precision * recall}{\beta^2 * precision + recall})$$

$$\beta = 2$$

Важнее полнота



# **Метрики качества ранжирования**

# Классификатор

Линейный классификатор:

$$a(x) = \text{sign}(\langle w, x \rangle - t) = 2[\langle w, x \rangle > t] - 1$$

$\langle w, x \rangle$  - оценка принадлежности классу +1

Нередко  $t = 0$

# Оценка принадлежности

Как оценить качество  $b(x)$  ?

Порог зависит от ограничений на точность и полноту

# Оценка принадлежности

Высокий порог:

- Мало объектов относим к +1
- Точность выше
- Полнота ниже

• Низкий порог:

- Много объектов относим к +1
- Точность ниже
- Полнота выше

# Оценка принадлежности


|      |      |      |      |      |     |      |     |      |     |
|------|------|------|------|------|-----|------|-----|------|-----|
| -1   | -1   | +1   | -1   | -1   | -1  | +1   | +1  | -1   | +1  |
| 0.01 | 0.09 | 0.12 | 0.15 | 0.29 | 0.4 | 0.48 | 0.6 | 0.83 | 0.9 |

|      |      |      |      |      |     |      |     |      |     |
|------|------|------|------|------|-----|------|-----|------|-----|
| -1   | -1   | +1   | -1   | -1   | -1  | +1   | +1  | -1   | +1  |
| 0.01 | 0.09 | 0.12 | 0.15 | 0.29 | 0.4 | 0.48 | 0.6 | 0.83 | 0.9 |

|      |      |      |      |      |     |      |     |      |     |
|------|------|------|------|------|-----|------|-----|------|-----|
| -1   | -1   | +1   | -1   | -1   | -1  | +1   | +1  | -1   | +1  |
| 0.01 | 0.09 | 0.12 | 0.15 | 0.29 | 0.4 | 0.48 | 0.6 | 0.83 | 0.9 |


# PR-кривая

- Кривая точности-полноты
- Ось X — полнота
- Ось Y — точность
- Точки — значения точности и полноты при последовательных порогах






# PR-кривая



|        |      |      |      |      |      |      |
|--------|------|------|------|------|------|------|
| $b(x)$ | 0.14 | 0.23 | 0.39 | 0.52 | 0.73 | 0.90 |
| $y$    | 0    | 1    | 0    | 0    | 1    | 1    |

# PR-кривая в реальности




# PR-кривая

Левая точка:  $(0, 0)$  или  $(0, 1)$



Правая точка:  $(1, r)$ ,  $r$  – доля положительных объектов

Для идеального классификатора проходит через  $(1, 1)$

AUC-PRC – площадь под PR-кривой



# PR-кривая



# ROC-кривая


- Receiver Operating Characteristic

- Ось X — False Positive Rate

$$FPR = \frac{FP}{FP + TN}$$

- Ось Y - True Positive Rate

$$TPR = \frac{TP}{TP + FN}$$



# ROC-кривая

Для каждого значения порога  $t$  вычислим:

- **False Positive Rate** - долю неверно принятых объектов
- **True Positive Rate** - долю верно принятых объектов

Кривая, состоящая из точек с координатами  $(FPR, TPR)$  для всех возможных порогов - это и есть ROC-кривая.

# ROC-кривая

*AUC (Area Under Curve)* - площадь под ROC-кривой.


$$AUC \in [0; 1] .$$

- $AUC = 1$  -

идеальная классификация

- $AUC = 0.5$  -

случайная классификация



# ROC-кривая Пример

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

|        |     |     |     |     |      |
|--------|-----|-----|-----|-----|------|
| $b(x)$ | 0.2 | 0.4 | 0.1 | 0.7 | 0.05 |
| $y$    | -1  | +1  | -1  | +1  | +1   |

- Упорядочим объекты по убыванию предсказаний:

(0.7, 0.4, 0.2, 0.1, 0.05)

**1 шаг:**  $t = 0.7$ , то есть

$$a(x) = [b(x) > 0.7]$$

$$TPR = \frac{0}{0+3} = 0, \quad FPR = \frac{0}{0+2} = 0.$$

$$TPR = \frac{TP}{TP+FN}$$

$$FPR = \frac{FP}{FP+TN}$$



# ROC-кривая Пример

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

|        |     |     |     |     |      |
|--------|-----|-----|-----|-----|------|
| $b(x)$ | 0.2 | 0.4 | 0.1 | 0.7 | 0.05 |
| $y$    | -1  | +1  | -1  | +1  | +1   |


- Упорядочим объекты по убыванию предсказаний:  
(0.7, 0.4, 0.2, 0.1, 0.05)

**1 шаг:**  $t = 0.7$ , то есть

$$a(x) = [b(x) > 0.7]$$

$$TPR = \frac{0}{0+3} = 0,$$

$$FPR = \frac{0}{0+2} = 0.$$



# ROC-кривая Пример

- Оценки принадлежности к классу +1:

|        |     |     |     |     |      |
|--------|-----|-----|-----|-----|------|
| $b(x)$ | 0.2 | 0.4 | 0.1 | 0.7 | 0.05 |
| $y$    | -1  | +1  | -1  | +1  | +1   |

- Упорядочим объекты по

убыванию предсказаний:


(0.7, 0.4, 0.2, 0.1, 0.05)

**2 шаг:**  $t = 0.4$ , то есть

$$a(x) = [b(x) > 0.4]$$

$$TPR = \frac{1}{1+2} = \frac{1}{3},$$

$$FPR = \frac{0}{0+2} = 0.$$



# ROC-кривая Пример

- Оценки принадлежности к классу +1:

|        |     |     |     |     |      |
|--------|-----|-----|-----|-----|------|
| $b(x)$ | 0.2 | 0.4 | 0.1 | 0.7 | 0.05 |
| $y$    | -1  | +1  | -1  | +1  | +1   |

- Упорядочим объекты по

убыванию предсказаний:


(0.7, 0.4, 0.2, 0.1, 0.05)

**3 шаг:**  $t = 0.2$ , то есть

$$a(x) = [b(x) > 0.2]$$

$$TPR = \frac{2}{2+1} = \frac{2}{3},$$

$$FPR = \frac{0}{0+2} = 0.$$



# ROC-кривая Пример

- Оценки принадлежности к классу +1:

|        |     |     |     |     |      |
|--------|-----|-----|-----|-----|------|
| $b(x)$ | 0.2 | 0.4 | 0.1 | 0.7 | 0.05 |
| $y$    | -1  | +1  | -1  | +1  | +1   |

- Упорядочим объекты по

убыванию предсказаний:


(0.7, 0.4, 0.2, 0.1, 0.05)

**4 шаг:**  $t = 0.1$ , то есть

$$a(x) = [b(x) > 0.1]$$

$$TPR = \frac{2}{2+1} = \frac{2}{3},$$

$$FPR = \frac{1}{1+1} = \frac{1}{2}.$$



# ROC-кривая Пример

- Оценки принадлежности к классу +1:

|        |     |     |     |     |      |
|--------|-----|-----|-----|-----|------|
| $b(x)$ | 0.2 | 0.4 | 0.1 | 0.7 | 0.05 |
| $y$    | -1  | +1  | -1  | +1  | +1   |

- Упорядочим объекты по

убыванию предсказаний:


(0.7, 0.4, 0.2, 0.1, 0.05)

**5 шаг:**  $t = 0.05$ , то есть

$$a(x) = [b(x) > 0.05]$$

$$TPR = \frac{2}{2+1} = \frac{2}{3},$$

$$FPR = \frac{2}{2+0} = 1.$$



# ROC-кривая Пример

- Оценки принадлежности к классу +1:

|        |     |     |     |     |      |
|--------|-----|-----|-----|-----|------|
| $b(x)$ | 0.2 | 0.4 | 0.1 | 0.7 | 0.05 |
| $y$    | -1  | +1  | -1  | +1  | +1   |

- Упорядочим объекты по

убыванию предсказаний:


(0.7, 0.4, 0.2, 0.1, 0.05)

**5 шаг:**  $t = 0$ , то есть

$$a(x) = [b(x) > 0]$$

$$TPR = \frac{3}{3+0} = 1,$$

$$FPR = \frac{2}{2+0} = 1.$$



# ROC-кривая

- Receiver Operating Characteristic

- Ось X — False Positive Rate

$$FPR = \frac{FP}{FP + TN}$$


$FP + TN$  — число отрицательных объектов

- Ось Y - True Positive Rate


$$TPR = \frac{TP}{TP + FN}$$

$TP + FN$  — число положительных объектов

=




# ROC-кривая



|        |      |      |      |      |      |      |
|--------|------|------|------|------|------|------|
| $b(x)$ | 0.14 | 0.23 | 0.39 | 0.52 | 0.73 | 0.90 |
| $y$    | 0    | 1    | 0    | 0    | 1    | 1    |




# ROC-кривая в реальности





# ROC-кривая

- Левая точка:  $(0, 0)$
- Правая точка:
- Для идеального классификатора проходит через  $(0, 1)$
- AUC-ROC — площадь под ROC-кривой



# ROC-кривая



# AUC-ROC

$$FPR = \frac{FP}{FP + TN}$$

$$TPR = \frac{TP}{TP + FN}$$

FP и TP нормируются на размеры классов

- AUC-ROC не поменяется при изменении баланса классов
- Учитывает True Negatives
- Идеальный алгоритм:  $AUC - ROC = 1$
- Худший алгоритм:  $AUC - ROC \approx 0.5$

# AUC-PRC

$$precision = \frac{TP}{TP + FP}$$

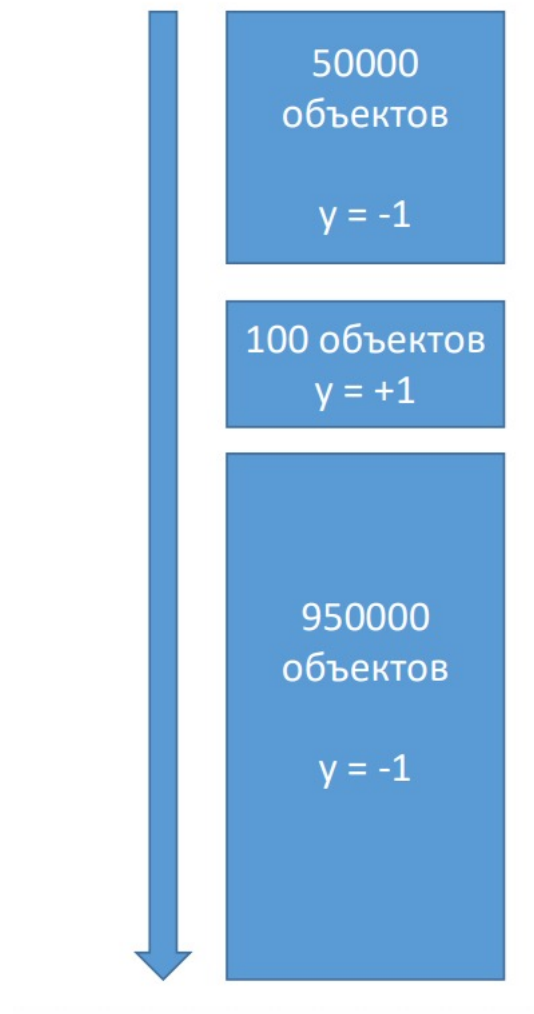
$$recall = \frac{TP}{TP + FN}$$

- Точность поменяется при изменении баланса классов
- AUC-PRC идеального алгоритма зависит от баланса классов
- Не учитывает True Negatives
- Проще интерпретировать, если выборка несбалансированная
- Лучше, если задачу надо решать в терминах точности и полноты

# Пример

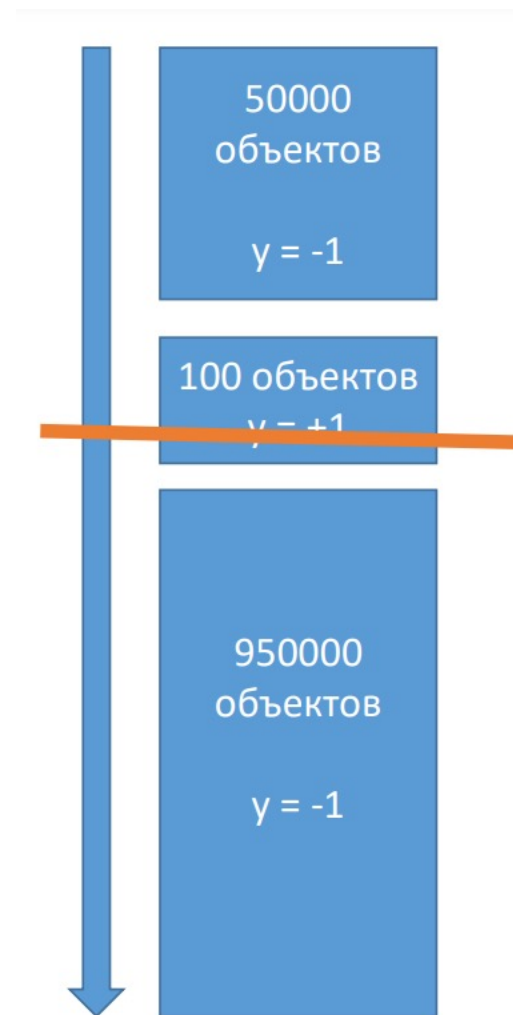
$$AUC - ROC = 0.95$$

$$AUC - PRC = 0.001$$



# Пример

- Выберем конкретный классификатор
- $a(x) = 1$  — 50095 объектов
- Из них FP = 50000, TP = 95
- TPR = 0.95, FPR = 0.05
- precision = 0.0019, recall = 0.95



# Спасибо за внимание!



**Ildar Safilo**

**@Ildar\_Saf**

**irsafilo@gmail.com**

**<https://www.linkedin.com/in/isafilo/>**